

Згадаємо постановку задачі у класичному регресійному аналізі. Вважаємо, що для регресійної моделі

$$y = X\alpha + e$$

справедливі усі припущення класичного регресійного аналізу:

- I. $e \sim \mathcal{N}(\theta_N, \sigma^2 E_N), \sigma^2 \in \mathbb{R}_+,$
- II. $\text{rank}(X) = p,$
- III. немає ніяких обмежень на α , тобто $\alpha \in \mathbb{R}^p.$

Введемо позначення $Q(\alpha) = \|y - X\alpha\|^2$. Тоді відомо, що при справедливості припущень I, II, III оцінка МНК є розв'язком такої оптимізаційної задачі

$$\hat{\alpha} = \arg \min_{\alpha} Q(\alpha) = (X^T X)^{-1} X^T y.$$

Послабимо тепер припущення II, а саме будемо вважати, що матриця X задовольняє умові:

$$\text{II}'. \text{rank}(X) = p - r, \quad r \geq 1. \quad (0.39)$$

Припущення II' еквівалентно умові, що стовпчики матриці X лінійно залежні, тобто що

$$\exists a_i \neq \bar{\theta}_p : Xa_i = \bar{\theta}_N, i = \overline{1, r}. \quad (0.40)$$

Якщо справедливі припущення I, II', III, тобто умова (0.40) виконується строго, то кажуть, що знаходяться в умовах *строгої мультиколінеарності*, якщо ж умова (0.40) виконується не строго, тобто добутки Xa_i попадають тільки в окіл початку координат, то кажуть, що знаходяться в умовах *мультиколінеарності*.

Проаналізуємо обидва ці випадки.

Випадок строгої мультиколінеарності. У цьому випадку оцінка МНК існує і вона буде не єдина. А множина цих усіх оцінок МНК задається як множина усіх розв'язків системи нормальних рівнянь для оцінки МНК, а саме:

$$(X^T X) \hat{\alpha} = X^T y.$$

Зауважимо, що в умовах строгої мультиколінеарності оцінка МНК у вигляді

$$\hat{\alpha} = (X^T X)^{-1} X^T y \quad (0.41)$$

не існує.

Випадок мультиколінеарності. В умовах мультиколінеарності оцінка МНК у вигляді (0.41) теоретично існує, бо матриця $(X^T X)$ є не виродженою, але її практичне використання буде проблематичним. Дійсно справедливості умов мультиколінеарності

приводить до того, що існують власні значення матриці $(X^T X)$, які попадають в окіл нуля, а це означає, що $\det(X^T X)$ буде близьким до нуля, тобто матриця $(X^T X)$ буде погано обумовленою. А це у свою чергу приводить до таких негативних наслідків для оцінки МНК у вигляді (0.41):

- Оцінка МНК у вигляді (0.41) буде вже нестійкою. Тобто незначні зміни в елементах матриці X можуть привести до значної зміни значень оцінок параметрів $\hat{\alpha} = (X^T X)^{-1} X^T y$.

Свій внесок до цього додадуть також похибки машинного округлення. А це у свою чергу приводить до втрати точності прогнозу згідно нашої моделі.

- Оцінка МНК у вигляді (0.41) буде вже мало ефективною, бо її характеристика розсіювання $\sigma^2 (X^T X)^{-1}$ різко зростає. Згадайте властивість I.a. $\hat{\alpha} \sim \mathcal{N}(\alpha, \sigma^2 (X^T X)^{-1})$.
- Параметри регресійної моделі будуть сильно корельовані між собою згідно властивості I.a. $\hat{\alpha} \sim \mathcal{N}(\alpha, \sigma^2 (X^T X)^{-1})$. А це вже позбавляє змісту їх інтерпретацію.

Для подолання цих проблем при оцінюванні параметрів регресійної моделі в умовах мультиколінеарності використовують:

- Попереднє центрування незалежних змінних.
- При поліноміальній апроксимації функції регресії переходять від регресорів $\{x^i\}_{i=0}^p$ до регресорів у вигляді набору ортогональних поліномів $\{\phi_i(x)\}_{i=0}^p$.
- Гребеневі оцінки.

Найбільш вживаним підходом є використання гребеневих оцінок.

Гребенева оцінка (ridge estimate).

Гребенева оцінка була запропонована Хоерлом (A. Hoerl) у 1962 році і визначається таким чином:

$$\hat{\alpha}(\varepsilon) = (X^T X + \varepsilon E_p)^{-1} X^T y, \varepsilon > 0, \quad (0.42)$$

де ε – мале позитивне дійсне число.

Ця оцінка дозволяє подолати погано обумовленість матриці $(X^T X)$. Але з'ясувалося, що гребенева оцінка є зміщеною і це призвело до відтермінування її широкого використання на практиці. Але згодом з'ясувалося, що гребенева оцінка при коректному виборі параметра ε дозволяє досягти навіть більшої точності у середньо квадратичному розумінні у порівнянні з оцінкою МНК $\hat{\alpha} = (X^T X)^{-1} X^T y$. Саме це відновило інтерес до використання на практиці гребневої оцінки.

Введемо позначення: $B(\varepsilon) = (X^T X + \varepsilon E_p)^{-1}$. Це дозволяє гребеневу оцінку записати у такому вигляді

$$\hat{\alpha}(\varepsilon) = B(\varepsilon) X^T y, \varepsilon > 0. \quad (0.43)$$

Т е о р е м а. Для гребневої оцінки $\hat{\alpha}(\varepsilon)$ справедливо:

- 1) $\hat{\alpha}(\varepsilon) = [E_p - \varepsilon B(\varepsilon)] \hat{\alpha}$, де $\hat{\alpha} = (X^T X)^{-1} X^T y$,
- 2) $M \hat{\alpha}(\varepsilon) = \alpha + \Delta(\hat{\alpha}(\varepsilon))$, де $\Delta(\hat{\alpha}(\varepsilon)) = -\varepsilon B(\varepsilon) \alpha$,
- 3) $m(\varepsilon) = M \|\hat{\alpha}(\varepsilon) - \alpha\|^2 = M \|\hat{\alpha}(\varepsilon) - M \hat{\alpha}(\varepsilon)\|^2 + \|\Delta(\hat{\alpha}(\varepsilon))\|^2$.

гребневої оцінки


$$\begin{aligned} m(\varepsilon) &= M \|\hat{\alpha}(\varepsilon) - \alpha\|^2 = M \|\hat{\alpha}(\varepsilon) - M \hat{\alpha}(\varepsilon) + M \hat{\alpha}(\varepsilon) - \alpha\|^2 = \\ &= M \left\| \left(\hat{\alpha}(\varepsilon) - M \hat{\alpha}(\varepsilon) \right) + \underbrace{\left(M \hat{\alpha}(\varepsilon) - \alpha \right)}_{\Delta(\hat{\alpha}(\varepsilon))} \right\|^2 = \end{aligned}$$

$$\begin{aligned}
&= M \|\hat{\alpha}(\varepsilon) - M\hat{\alpha}(\varepsilon)\|^2 + 2M \left\{ (\hat{\alpha}(\varepsilon) - M\hat{\alpha}(\varepsilon))^T \Delta(\hat{\alpha}(\varepsilon)) \right\} + \\
&+ \|\Delta(\hat{\alpha}(\varepsilon))\|^2 = M \|\hat{\alpha}(\varepsilon) - M\hat{\alpha}(\varepsilon)\|^2 + \\
&+ 2M \left\{ (\hat{\alpha}(\varepsilon) - M\hat{\alpha}(\varepsilon))^T \Delta(\hat{\alpha}(\varepsilon)) \right\} + \|\Delta(\hat{\alpha}(\varepsilon))\|^2 = \\
&= M \|\hat{\alpha}(\varepsilon) - M\hat{\alpha}(\varepsilon)\|^2 + 2 \left\{ \underbrace{(M\hat{\alpha}(\varepsilon) - M\hat{\alpha}(\varepsilon))^T}_{\theta_p} \Delta(\hat{\alpha}(\varepsilon)) \right\} + \\
&+ \|\Delta(\hat{\alpha}(\varepsilon))\|^2 = M \|\hat{\alpha}(\varepsilon) - M\hat{\alpha}(\varepsilon)\|^2 + \|\Delta(\hat{\alpha}(\varepsilon))\|^2.
\end{aligned}$$


Зауваження 1. Згідно п. 3 теореми

$$m(\varepsilon) = M \|\hat{\alpha}(\varepsilon) - \alpha\|^2 = \underbrace{M \|\hat{\alpha}(\varepsilon) - M\hat{\alpha}(\varepsilon)\|^2}_{m_1(\varepsilon)} + \underbrace{\|\Delta(\hat{\alpha}(\varepsilon))\|^2}_{m_2(\varepsilon)}.$$

Зауваження 1 (Херл, Кенард; 1970).



Зауваження 2.



$\eta \in \epsilon_0$ - найменши ϵ при якому відбулася стабілізація
усіх градієнтів $\hat{L}_i(\epsilon)$

Методи вибору структури регресійної моделі

η : $y(1), \dots, y(N)$.

Ми маємо дані на p регресорів

$\varphi_i(\vec{x}) : x_i(1), \dots, x_i(N), i = \overline{1, p}$

I. Метод включення

II. Метод виключення

III. Прямі крокові регресії

IV. Обернені крокові регресії

Позн: $I = \{0, 1, 2, \dots, p\}$

Зауваження. Замість
змінної η маємо
вектор 0 . $\eta \equiv \vec{\xi}_0$

I. Метод включення

Почат. модель:

$$y(k) = \alpha_0 + e_+(k), \quad k = \overline{1, N}$$

Iдея: ...

1. $I_- := \{1, 2, \dots, p\}; \quad \tilde{p} := 1; \quad \delta > 0;$

2. ~~...~~

$$I_i := I \setminus \{0, i\}$$

$$\hat{\alpha}_{0i}(I_i), \quad i \in I_-$$

3. $i_+ = \arg \max_{i \in I_-} |\hat{\alpha}_{0i}(I_i)|$

$$4. \quad F_{i+} < F_{j+} (1, N - (\tilde{\gamma} + 1))$$

⊕ /
 $\psi_{i+}(\frac{\tilde{\gamma}}{2})$ - не выкидывать;
 stop;

⊖ \
 $\psi_{i+}(\frac{\tilde{\gamma}}{2})$ - выкидываем;
 $\tilde{p} := \tilde{p} + 1$;
 $I_+ := I_+ \setminus \{i+1\}$;
 if $\tilde{p} = p+1$ then stop;
 goto n. 2;

II. Метод выкидывания

Поток данных:
 $I_{\text{вх}}: \dots$

$$y(k) = d_0 + \sum_{i=1}^p d_i x_i(k) + e_-(k), \quad k = \overline{1, N}$$

$$1. \quad I_+ := \{1, 2, \dots, p\}, \quad \tilde{p} = p+1, \quad \delta \rightarrow 0;$$

$$2. \quad F_i, \quad i \in I_+$$

$$3. \quad i_- = \underset{i \in I_+}{\operatorname{argmin}} F_i;$$

$$4. \quad F_{i_-} < F_{j_-} (1, N - \tilde{p})$$

⊕ /
 $\psi_{i_-}(\frac{\tilde{\gamma}}{2})$ - выкидываем;
 $\tilde{p} := \tilde{p} - 1$;

⊖ \
 $\psi_{i_-}(\frac{\tilde{\gamma}}{2})$ - не выкидывать;
 stop;

$$I_+ := I_+ \setminus \{i_-\};$$

if $\tilde{p} = 1$ then stop;

goto n. 2;

Порівняння \bar{I}, \bar{II} .

III. Алгоритм крокової регресії

Почат. модель $y(k) = \alpha_0 + e_+(k)$, $k = \bar{1}, \bar{N}$.
Ідея: ...

1. $I_- := \{1, 2, \dots, p\}$; $I_+ := \{\}$;

$M := \emptyset$; // кількість ^{попер.} послідовних невдалих кроків

$\tilde{p} := 1$; $\gamma_- \geq \gamma_+ > 0$;

2. $z_{0i}(I_-)$, $i \in \begin{cases} I_- & \text{// на першій ітерації} \\ I_- \setminus \{i-3\} \end{cases}$;

де $I_- := I \setminus \{0, i\}$;

3. $i_+ = \operatorname{argmax}_{i \in \begin{cases} I_- & \text{// на першій ітерації} \\ I_- \setminus \{i-3\} \end{cases}} |z_{0i}(I_-)|$;

4. $F_{i+} < F_{\gamma_+} (1, N - (\tilde{p} + 1))$

(+)

(-)

$\psi_{i+}(\vec{\gamma})$ - не вказує;

if $M = 1$ then stop;

$M := 1$;

if $\tilde{p} = 1$ then stop;

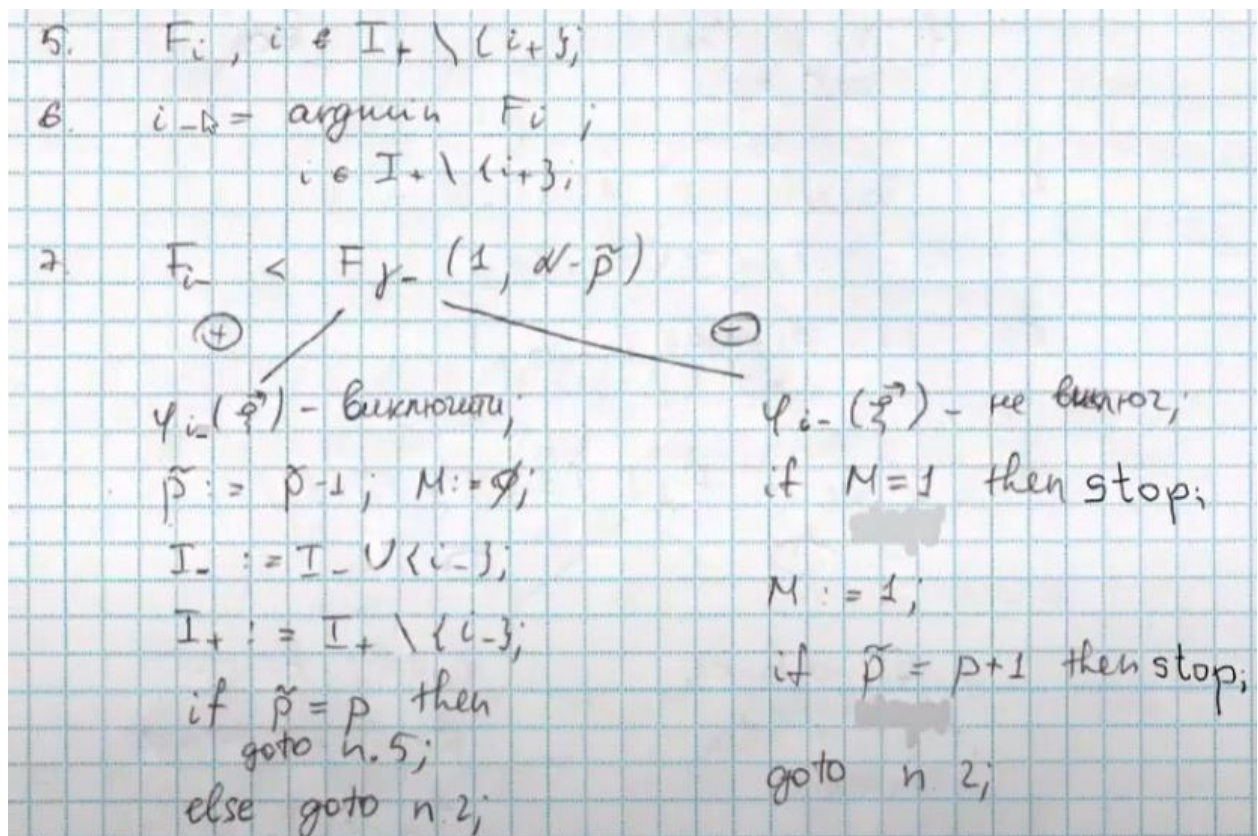
$\psi_{i+}(\vec{\gamma})$ - вказує;

$\tilde{p} := \tilde{p} + 1$; $M := \emptyset$;

$I_- := I_- \setminus \{i_+\}$;

$I_+ := I_+ \cup \{i_+\}$;

if $\tilde{p} = 2$ then
goto n. 2;



IV. Обернутое кроковое пересечение

Потенц. модель: $y(k) = \alpha_0 + \sum_{i=1}^p \alpha_i X_i(k) + e(k), k=1, N$

Идея: ...

1. $I_- := \{ \}; I_+ := \{1, 2, \dots, p\};$
 $M := \emptyset; \tilde{p} := p+1; \gamma_- \geq \gamma_+ > 0;$
2. $F_i, i \in \begin{matrix} I_+ \\ I_+ \setminus \{i+y\} \end{matrix}$ // первое пересечение
3. $i_- = \argmin_{i \in \begin{matrix} I_+ \\ I_+ \setminus \{i+y\} \end{matrix}} F_i$ // первое пересечение

$$4. \quad F_{i-} < F_{\gamma-}(1, N-\tilde{\beta})$$

⊕
⊖

$\psi_{i-}(\vec{\xi})$ - не лучший;

$\tilde{p} := \tilde{p} - 1; M := \emptyset;$

$I_- := I_- \cup \{i-\};$

$I_+ := I_+ \setminus \{i-\};$

if $\tilde{p} = p$ then goto n.2;

$\psi_{i-}(\vec{\xi})$ - не лучший;

if $M = 1$ then stop;

$M := 1;$

if $\tilde{p} = p+1$ then stop;

5. $\hat{\Sigma}_{\alpha}(I_i), i \in I_- \setminus \{i-\},$
 or $I_i := I \setminus \{0, i\};$

6. $i_+ = \operatorname{argmax}_{i \in I_- \setminus \{i-\}} |\hat{\Sigma}_{\alpha}(I_i)|$

$$7. \quad F_{i+} < F_{\gamma+}(1, N-(\tilde{p}+1))$$

⊕
⊖

$\psi_{i+}(\vec{\xi})$ - не лучший;

if $M = 1$ then stop;

$M := 1;$

if $\tilde{p} = 1$ then stop;

goto n.2;

$\psi_{i+}(\vec{\xi})$ - лучший;

$\tilde{p} := \tilde{p} + 1; M := \emptyset;$

$I_- := I_- \setminus \{i_+\};$

$I_+ := I_+ \cup \{i_+\};$

if $\tilde{p} = 2$ then goto n.5.

goto n.2;

Нелінійний регресійний аналіз

$$y(k) = g(x(k), \vec{\alpha}) + e(k), \quad k = \overline{1, N} \quad (15)$$

Нехай (15) є нелінійною по $\vec{\alpha}$.

Нелінійні регресійні моделі класифікуються на два класи:

- 1) внутрішньолінійні;
- 2) внутрішньонелінійні.

Озн. Моделі називаються внутрішньолінійними, якщо шляхом перетворень її можна привести до лінійної по параметрам, інакше модель є внутрішньонелінійною.

1) Логіст. $y(k) = \ln(\alpha_1) x(k)^{\alpha_2} + e(k), \quad k = \overline{1, N}$

$$\ln y(k) = \ln \ln(\alpha_1) + \alpha_2 \ln(x(k)) + \tilde{e}(k), \quad k = \overline{1, N}$$

$$\text{Нехай } \tilde{y}(k) = \ln(y(k)), \quad \beta_1 = \ln \ln(\alpha_1), \quad \beta_2 = \alpha_2$$

$$\tilde{x}(k) = \ln(x(k)), \quad \tilde{e}(k) = \dots, \text{ тоді}$$

$$\tilde{y}(k) = \beta_1 + \beta_2 \tilde{x}(k) + \tilde{e}(k), \quad k = \overline{1, N}$$

За допомогою МНК знаходимо $\hat{\beta}_1, \hat{\beta}_2$, тоді

$$\begin{cases} \hat{\beta}_1 = \ln \ln(\hat{\alpha}_1) \\ \hat{\beta}_2 = \alpha_2 \end{cases} \Rightarrow \begin{cases} \hat{\alpha}_1 = e^{e^{\hat{\beta}_1}} \\ \hat{\alpha}_2 = \log_2(\hat{\beta}_2) \end{cases}$$

Зауваження. Так як ми працюємо з $\tilde{e}(k)$, а не $e(k)$, то такі оцінки варто приймати як деяке наближення до істинних оцінок НК функційної моделі.

Якщо модель (15) вбудовують лінійно, тоді існують деякі функції $g_1(\cdot)$, $\{g_2(\cdot)\}$, $\{g_{3j}(\cdot)\}$, що справедливі

$$g_1(y(k)) = \sum_j \beta_j g_{3j}(x(k)) + \tilde{e}(k), \quad k = \overline{1, N}, \quad (16)$$

$$\text{де } \{\hat{\beta}_j = g_{3j}(\hat{z}), \forall j\} \quad (17)$$

З системою (16) за допомогою НК знаходимо $\{\hat{\beta}_j\}$
А з (17), внаслідок взаємності $\{\hat{\beta}_j\}$ знаходять \hat{z} .

2) Вибір функційнокалінійної системи (15)

$$\hat{z} = \underset{\alpha}{\operatorname{argmin}} \sum_{k=1}^N e^2(k) = \underset{\alpha}{\operatorname{argmin}} I(\alpha).$$

$$\text{де } I(\alpha) = \sum_{k=1}^N e^2(k)$$

За допомогою методів безумовної нелінійної оптимізації мінімізуємо функціонал $I(\alpha)$.

Наприклад. Метод Маркварта

(градієнтний + лінеаризації)